

NLP 情感分析考核报告

方向：自然语言处理 (NLP)

阶段一：文献综述 + 阶段二：BERT 微调实验

模型：BERT-base-uncased 微调

2026 年 6 月 7 日

一 阶段一：文献综述

1.1 摘要

文本情感分析 (Sentiment Analysis) 是自然语言处理 (NLP) 的核心任务之一，旨在自动识别文本中蕴含的情感倾向 (正面/负面)。从 Pang et al. (2002) 首次将机器学习系统应用于电影评论情感分类，到 Devlin et al. (2019) 提出 BERT 开启「预训练+微调」新范式，该领域经历了从手工特征到深层语义理解的深刻变革。本综述以 IMDB 电影评论情感分析为主线，沿技术演进脉络梳理了五个里程碑式的工作——Pang et al. (2002) 的传统 ML 方法、Mikolov et al. (2013) 的 Word2Vec 词向量、Kim (2014) 的 TextCNN、Vaswani et al. (2017) 的 Transformer，以及 Devlin et al. (2019) 的 BERT——分析各阶段的核心思想、关键贡献与内在局限，并结合本次实验进行讨论。

1.2 技术演进路线

情感分析技术的发展大致经历了四个阶段：（1）基于词袋模型和统计分类器的传统方法（2002 年前后）；（2）以 Word2Vec 为代表的稠密词向量（2013 年）；（3）CNN/LSTM 等深度神经网络（2014 年）；（4）以 Transformer 和 BERT 为核心的预训练大模型时代（2017-2019 年）。每个阶段都在前一个阶段的基础上解决了关键瓶颈，但也不可避免地引入了新的挑战。

1.3 传统方法：BoW + 统计分类器

核心工作：Pang et al. (2002)

Pang, Lee 和 Vaithyanathan 在 EMNLP 2002 上发表了「Thumbs up? Sentiment Classification using Machine Learning Techniques」，首次将朴素贝叶斯 (Naive Bayes)、最大熵 (Maximum Entropy) 和支持向量机 (SVM) 三种机器学习方法系统应用于 IMDB 电影评论的情感分类。他们发现：使用 unigram 特征 (单个词) 比 bigram (词组) 效果更好——这与信息检索领域的直觉相反；二值特征 (词是否出现) 比词频 (词出现几次) 更有效；三种分类器中 SVM 取得了最佳效果，准确率达 82.9%。

关键发现: Pang et al. 指出「*classifiers tend to be confused by reviews that contain both positive and negative sentiments, or by reviews that use irony or sarcasm*」——这个 2002 年就发现的问题, 至今仍是 BERT 等先进模型面临的挑战。

贡献与局限

Pang et al. 的开创性贡献在于: (1) 首次将情感分类形式化为标准的机器学习问题, 奠定了该领域的实验范式; (2) 系统比较了不同分类器和特征组合的效果, 为后续工作提供了基准。然而, BoW 方法存在根本性缺陷: 它完全忽略了词序和上下文。例如「not good」和「good」在 BoW 表示中几乎无法区分——因为模型只看到「not」和「good」各自独立出现, 无法理解两者组合后的语义反转。这种对词序的无视, 直接催生了后来对词向量和序列模型的探索。

1.4 词向量革命: Word2Vec

核心工作: Mikolov et al. (2013)

Mikolov 等人在 ICLR 2013 上提出了 Word2Vec, 包含 CBOW (Continuous Bag-of-Words) 和 Skip-gram 两种架构。核心思想是将每个词映射为一个低维稠密向量 (通常 100-300 维), 使得语义相近的词在向量空间中距离较近。论文提出了负采样 (Negative Sampling) 和分层 Softmax 等训练技巧, 使得在数十亿词规模语料上训练词向量成为可能。

最著名的发现: $\text{vec}(\text{King}) - \text{vec}(\text{Man}) + \text{vec}(\text{Woman}) \approx \text{vec}(\text{Queen})$ ——词向量不仅能表示语义相似性, 还能编码词之间的类比关系。这是 BoW 离散表示完全无法做到的。

贡献与局限

Word2Vec 的核心贡献在于: (1) 实现了从离散符号到连续语义空间的跨越, 让 NLP 模型第一次能「理解」词与词之间的语义关系; (2) 通过高效的训练技巧, 使大规模词向量训练变得实用可行。但其关键局限在于: 每个词只有一个固定的向量表示, 无法处理一词多义。例如「bank」在「river bank」(河岸) 和「money bank」(银行) 中含义完全不同, 但 Word2Vec 给两者分配同一个向量。这个局限直接推动了后来 ELMo (2018) 和 BERT (2019) 等上下文相关表示的发展。

1.5 深度学习入局: TextCNN

核心工作: Kim (2014)

Kim 在 EMNLP 2014 上发表了仅 4 页的短文「Convolutional Neural Networks for Sentence Classification」, 将计算机视觉中成熟的 CNN 架构迁移到文本分类。核心设计为: (1) 在预训练的 Word2Vec 词向量之上叠加卷积层; (2) 使用多个不同尺寸的卷积核 ($h=3,4,5$), 分别捕获 3-gram、4-gram、5-gram 级别的局部语义模式; (3) 通过最大池化 (Max-over-Time Pooling) 提取每个卷积核的最强激活特征, 实现位置不变性; (4) 实验了静态词向量 (不微调) 和非静态词向量 (微调) 两种模式。

关键发现: 非静态模式 (允许微调词向量) 效果显著优于静态模式——这本质上是「预训练+微调」范式的早期雏形。在电影评论 (MR) 数据集上准确率达 81.5%, 超越了当时多数复杂模型。

贡献与局限

TextCNN 的核心启示在于: 好的预训练表示 (Word2Vec) + 简单架构 (CNN) 优于复杂架构 + 差的表示。这个原则后来被 BERT 进一步放大。但 TextCNN 的局限也很明显: 卷积核的感受野有限 (3-5 个词), 无法建模长距离依赖关系。对于「I like this movie, but...」这种需要跨越半句话才能判断情感的转折结构, CNN 天然不足。这恰好为 RNN/LSTM 以及后来的 Self-Attention 机制提供了契机。

1.6 架构革命: Transformer 与 Self-Attention

核心工作: Vaswani et al. (2017)

Vaswani 等人在 NeurIPS 2017 上发表了「Attention Is All You Need」, 提出了完全基于自注意力 (Self-Attention) 机制的 Transformer 架构。核心公式为 $\text{Attention}(Q,K,V) = \text{softmax}(QK^T/\sqrt{d_k}) \times V$, 其中 Q (Query)、K (Key)、V (Value) 分别来自输入的不同线性投

影。Multi-Head Attention 让模型从多个不同的表示子空间同时关注序列中的不同位置。Positional Encoding 通过正弦/余弦函数为每个位置注入唯一的编码，以弥补并行处理导致的词序信息丢失。

关键突破：Transformer 抛弃了 RNN 的串行结构——所有位置同时计算——训练速度大幅提升，且从根本上解决了长距离依赖问题（任意两个词之间只需一步 Attention 即可直接通信）。

贡献与局限

Transformer 解决了三个核心问题：（1）并行计算——摆脱 RNN 的串行瓶颈，训练效率质的飞跃；（2）长距离依赖——Self-Attention 让每个词直接关注所有其他词；（3）多角度表示——Multi-Head Attention 使得模型能同时从句法、语义、指代等多个维度理解文本。其局限在于：Self-Attention 的计算复杂度为 $O(n^2)$ （ n 为序列长度），当 n 很大时计算开销极高。Transformer 本身只是一个架构——它需要通过预训练任务来获得语言知识，这正是 BERT 要解决的问题。

1.7 预训练范式确立：BERT

核心工作：Devlin et al. (2019)

Devlin 等人在 NAACL 2019 上提出了 BERT (Bidirectional Encoder Representations from Transformers)，将「预训练+微调」确立为 NLP 的主导范式。BERT 的核心创新在于：（1）掩码语言模型 (MLM) 预训练任务——随机遮盖 15% 的输入词，让模型根据双向上下文预测被遮盖的词——使得模型能同时利用左右两侧的信息；（2）下一句预测 (NSP) 任务——让模型学习句子间的关系；（3）[CLS] 标记设计——将整个序列的语义信息聚合到一个 768 维向量中，用于下游分类任务。BERT_base 拥有 12 层 Transformer、12 个注意力头、隐藏维度 768，共约 1.1 亿参数。

关键结果：BERT_base 在 GLUE 基准（共 11 个 NLP 任务）上平均超越此前 SOTA 7.7 个百分点。在情感分析等单句分类任务上，只需在 [CLS] 输出上添加一个简单的分类层（768→2），用极小的学习率（ 2×10^{-5} ）微调 3 个 Epoch，即可达到 90%+ 的准确率。

贡献与本实验的关系

BERT 的「预训练+微调」范式是本次实验的核心理论基础。预训练阶段（MLM，33 亿词语料）让 BERT 学会了通用的语言知识（语法、语义、常识），微调阶段只需教会模型一个具体任务（IMDB 情感分类）。这解释了为什么仅用 25,000 条标注数据、3 个 Epoch（约 23 分钟 GPU 训练），BERT 就能在 IMDB 上达到 92.12% 的准确率——相比之下，Pang et al. (2002) 用 SVM 做到 82.9%，Kim (2014) 用 TextCNN 做到约 81.5%。二十年间的进步不仅在于模型架构的升级，更在于范式转变：从「为每个任务从零设计特征和模型」到「在大规模预训练基础上轻量适配」。

1.8 方法对比

方法	代表工作	技术路线	IMDB 准确率	核心局限
BoW + SVM	Pang et al. (2002)	unigram + 二值特征 + SVM	~82.9%	忽略词序，无法处理否定和转折
Word2Vec + CNN	Kim (2014)	预训练词向量 + 多尺寸卷积核 + 最大池化	~81.5% (MR)	感受野有限，无法建模长距离依赖
Word2Vec + BiLSTM	Graves (2013) 等	预训练词向量 + 双向 LSTM + 全连接分类	~86.6% (示例)	串行训练慢，长序列梯度衰减
BERT 微调	Devlin et al. (2019)	Transformer 预训练 + [CLS] 分类头微调	92.12% (本次实验)	模型较大 (1.1 亿参数)，需要 GPU

1.9 个人思考

通过系统阅读这五篇里程碑论文，我对 NLP 情感分析技术的发展有了更深入的理解：

1. 第一，技术演进遵循「发现问题 → 提出方案 → 方案引入新问题 → 继续迭代」的融旋上升路径。Pang 发现 BoW 无法处理词序 → Mikolov 提出词向量 → 但静态向量无法处理一词多义 → BERT 实现上下文相关表示。每一步既是前一步的答案，也是下一步的问题。
2. 第二，Pang et al. (2002) 发现的「转折、讽刺、混合情感」等难点，在 Devlin et al. (2019) 的 BERT 上仍然存在。本实验的错误分析（第 5 节）中归纳的四种误判模式，与 2002 年的发现高度吻合——这说明这些不是工程问题，而是需要真正的语言理解才能解决的深层挑战。
3. 第三，「预训练+微调」是本领域最重要的范式转变。从 Kim 的「非静态词向量」到 BERT 的端到端微调，核心逻辑一脉相承：在通用知识的基础上做任务特异性适配。理解这个范式，比背住某个模型的具体参数更有价值。
4. 第四，学术研究中的「简单有效」原则值得学习。Kim 的 TextCNN 仅 4 页，Vaswani 的 Transformer 核心公式仅一行——但它们改变了整个领域的走向。在工程实践中，选择适合任务复杂度的方案，往往比堆砌复杂模型更重要。

二 实验环境

2.1 硬件环境

项目	配置
GPU	NVIDIA GeForce RTX 5060 Laptop GPU (8 GB VRAM)
CUDA	12.8
CPU	AMD 系列处理器
RAM	DDR5 系统内存

2.2 软件环境

库 / 工具	版本
Python	3.10
PyTorch	2.12.0.dev20260408+cu128
Transformers	4.47.0
datasets	3.2.0
scikit-learn	1.7.2
matplotlib / seaborn	3.10.9 / 0.13.2
numpy	2.2.6
tqdm	4.68.1

二 数据准备与预处理

2.1 IMDB 数据集

IMDB Movie Reviews 数据集包含 50,000 条英文电影评论，每条评论带有情感标签：label=1（正面）或 label=0（负面）。数据集正负样本各 25,000 条，分布均衡，无需额外处理类别不平衡问题。

2.2 数据集划分

按照考核要求，将原始训练集按 9:1 比例随机划分为训练集和验证集：

数据集	样本数	用途
训练集	22,500（原始训练集 90%）	模型参数学习

验证集	2,500 (原始训练集 10%)	监控过拟合, 选择最佳模型
测试集	25,000 (原始测试集全部)	最终性能评估

2.3 文本预处理

文本预处理包含以下四个步骤：

- 1. 分词 (Tokenization)：使用 bert-base-uncased 的 WordPiece 分词器，将原始文本转为 token ID 序列。分词器自动处理大小写统一 (uncased 模式) 和稀有词的子词拆分 (如 [unbelievable] → [un] + [##believable])。
- 2. 截断 (Truncation)：设置 max_length=256，超过部分从尾部截断。IMDB 评论平均长度约 230 词，256 覆盖了大部分评论内容。
- 3. 填充 (Padding)：不足 256 词的部分补零，同时生成 attention_mask 标记有效位置 (1 = 真实文本, 0 = 填充)。
- 4. 批处理 (Batching)：使用 DataLoader 按 batch_size=16 分组，训练集开启 shuffle=True 随机打乱。

二 BERT 微调实验

3.1 模型架构与超参数

- 1. 采用 HuggingFace 的 bert-base-uncased 预训练模型 (约 1.1 亿参数) 作为骨干网络。在 [CLS] 标记的 768 维输出向量上，添加一个全连接分类层 (768 → 2)，将语义向量映射为正面/负面两类的 logits 分数。

2. BERT 核心组件：12 层 Transformer Encoder，每层 12 个注意力头，隐藏维度 768，前馈网络中间层 3072，激活函数 GELU，Dropout 率 0.1。

3. 关键超参数配置如下：

超参数	取值	说明
MAX_LENGTH	256	IMDB 评论平均约 230 词，256 覆盖大部分
BATCH_SIZE	16	8 GB 显存的安全稳定值
LEARNING_RATE	2×10^{-5}	BERT 微调黄金学习率
NUM_EPOCHS	3	验证 Loss 在第 3 轮已开始上升
WEIGHT_DECAY	0.01	AdamW 正则化系数
优化器	AdamW	自适应学习率 + 权重衰减
学习率调度	线性衰减	学习率从 2×10^{-5} 线性衰减到 0
验证集比例	10%	从训练集中随机抽取

3.2 实验结果

表 1：BERT 训练过程

Epoch	训练 Loss	验证 Loss	验证 Acc	备注
1	0.2667	0.2209	91.00%	快速收敛
2	0.1319	0.2391	91.36%	持续提升
3	0.0511	0.2947	91.40%	过拟合信号

最终测试集结果：

指标	数值	评价
Accuracy	92.12%	超过 90% 优秀线
F1-Score	92.11%	与 Accuracy 接近
训练耗时	约 23 分钟	RTX 5060 GPU
误分类数	1,971 / 25,000	错误率 7.88%

3.3 Loss 曲线分析




图 1：训练 / 验证损失曲线

从 Loss 曲线可以观察到以下现象：

(1) 训练 Loss 持续大幅下降 ($0.27 \rightarrow 0.13 \rightarrow 0.05$)，说明模型在训练集上的拟合程度不断提高，优化过程正常收敛。

(2) 验证 Loss 在第 1 个 Epoch 后出现上升趋势 ($0.22 \rightarrow 0.24 \rightarrow 0.29$)，与训练 Loss 形成典型的「训练-验证背离」现象。这表明从第 2 个 Epoch 开始，模型已经出现过拟合——尽管此时验证准确率仍在缓慢上升。

(3) 验证准确率在 3 个 Epoch 内持续上升 ($91.00\% \rightarrow 91.36\% \rightarrow 91.40\%$)，说明 3 个 Epoch 是合理的训练截止点。若继续训练，验证 Loss 的上升趋势将最终导致验证准确率下降。

Loss 曲线分析是判断过拟合的核心方法——它比 Accuracy 更敏感。在本实验中，验证 Loss 从 Epoch 2 就已经发出了过拟合预警，而验证 Accuracy 的上升趋势掩盖了这一信号。

二 结果分析

4.1 混淆矩阵




图 2：测试集混淆矩阵

混淆矩阵各象限的含义及本实验数值：

象限	含义	数值	解读
左上 (TN)	真负例：负面 → 负面	约 11,528	识别负面能力强
右下 (TP)	真正例：正面 → 正面	约 11,501	识别正面能力强
右上 (FP)	假正面：负面 → 正面	972	7.88% 错误主要来源之一
左下 (FN)	假负面：正面 → 负面	999	与 FP 几乎相等

两类错误数量几乎相等（972 vs 999，差值仅 0.11%），说明模型没有系统性偏向某一类情感。这是数据正负样本平衡（各占 50%）的自然结果。

二 错误分析

5.1 总体统计

BERT 在 25,000 条测试集上共产生 1,971 条误分类，错误率为 7.88%。其中：

- 1. 假正面（负面 → 正面）：972 条 (49.3%)
- 2. 假负面（正面 → 负面）：999 条 (50.7%)

5.2 错误模式分类

通过对误分类样本的人工阅读和分析，归纳出以下四种典型错误模式：

模式一：转折句式

评论文本前半段使用大量正面词汇进行铺垫，后半段通过 but/however 转折后才表达真实负面评价。
BERT 虽然具备双向注意力机制，但对长距离转折关系的权重分配仍不够精准，容易被前半段的正面信号主导。

【例】*I'm the type of guy who loves hood movies... but this movie was something different.* (真实: 负面, 预测: 正面) ——前半段的 *loves* 等正面词导致模型误判

模式二：否定结构

否定词 (not, never, wasn't) 改变了所在句子的情感倾向。当否定词与关键情感词距离较远时, BERT 的自注意力机制难以准确将否定信号传导至目标词。

【例】*You probably will NOT like this movie.* (真实: 负面, 预测: 正面) ——*NOT* 虽强调否定, 但 *like* 的正面信号仍占据主导

模式三：混合情感（正负交织）

评论同时包含正面和负面评价, 模型需要判断整体情感倾向。当正负信号强度相近时, 模型倾向于被具体的、显性的正面词汇 (如 *enjoy*, *good*, *excellent*) 所主导, 而忽略负面的整体语境。

【例】*you'll probably enjoy this little flick... Beginning and end are pretty good, middle drags at times.* (真实: 负面, 预测: 正面) ——*enjoy* 和 *pretty good* 压过了整体负面评价

模式四：讽刺与含蓄表达

字面上使用正面词汇 (*excellent*, *good*, *great*) , 但实际表达的是讽刺或隐晦的负面评价。这种表达高度依赖文化背景和常识推理, 是当前纯文本预训练模型难以突破的瓶颈。

【例】*for an Al Adamson film, it's exceptional* ——表面赞扬 (*exceptional* = 极好) , 实为讽刺 (仅在他拍的烂片中算好的) 。 (真实: 负面, 预测: 正面)

5.3 典型案例

1. 案例 1: First off let me say, If you haven't enjoyed a Van Damme movie since bloodsport, you probably will not like this movie. ——前半段隐含对演员的正面期待, 后半段否定 (*will not like*) , 模型被前半段的 *enjoyed* 误导。

2. 案例 2: Low budget horror movie. If you don't raise your expectations too high, you'll probably enjoy this little flick. Beginning and end are pretty good, middle drags at times and seems to go nowhere for long stretches. ——enjoy、pretty good 等正面词连续出现，压过了整体的负面判断。

3. 案例 3: The only reason this movie is not given a 1 (awful) vote is that the acting of both Ida Lupino and Robert Ryan is superb. ——superb（极好）是强烈的正面信号，但整句实际在说除了演员的表演外一无是处。

5.4 改进建议

1. 增大 max_length: 从 256 提升到 512，减少截断损失，保留更多评论尾部的关键信息。尤其对于「先扬后抑」模式的评论，关键否定信息往往出现在评论后半段。
2. 尝试更强的预训练模型：使用 RoBERTa 或 DeBERTa 替换 BERT-base，这些模型在更大语料上进行了更充分的预训练，对否定和讽刺的理解能力更强。
3. 数据增强：针对转折/否定/讽刺类型的样本进行针对性增强，例如使用回译（back-translation）生成更多含 but/however 结构的训练样本。
4. 对抗训练：使用 FGM 或 PGD 在训练过程中对 embedding 层施加扰动，提升模型对语义微小变化的鲁棒性。

二 实验复盘与总结

6.1 调参经验

1. BERT 学习率 2×10^{-5} 是经论文和社区验证的黄金值。本实验验证了其合理性：训练过程平稳收敛，Loss 持续下降，未出现震荡或停滞。若从头再来，可对比尝试 3×10^{-5} 和 1×10^{-5} 。

2. 8 GB 显存条件下，batch_size=16 是稳定运行的上限。使用混合精度训练（AMP）理论上可提升至 32，更大的 batch 可能带来更稳定的梯度估计。
3. 3 个 Epoch 是合理的训练截止点。验证 Loss 在第 3 轮已明显上升，而验证 Acc 仍在缓慢上升——这是典型的「收益递减但风险递增」阶段，继续训练边际收益极低。
4. AdamW 的 weight_decay=0.01 提供了一定正则化效果，但第 3 轮验证 Loss 的上升表明过拟合仍在发生。可尝试增大至 0.05 或增加 Dropout 率。

6.2 代码实现经验

问题	解决方案	经验教训
网络代理无法下载模型和数据	改为本地 parquet + 本地 BERT 加载	离线加载策略是应对网络不稳定环境的必要技能
matplotlib 中文标题显示为方块	配置中文字体 + unicode_minus=False	Windows 下最常见的中文显示问题
Git 推送大文件失败 (3.5 GiB)	创建 .gitignore 排除 venv/Data/模型	大文件必须在仓库外管理
虚拟环境 pip 包缺失	激活 venv 后重新安装全部依赖	虚拟环境是空白的，系统包不会自动带入
错误分析需要原始评论文本	保留 dataset 原始引用，不过早 remove_columns	数据预处理需同时考虑训练和分析需求

6.3 关键收获

1. 第一，「预训练+微调」范式极大降低了 NLP 任务的门槛。只需在 BERT 上添加一个简单的分类头，用 3 个 Epoch、23 分钟的训练，就能达到 92.12% 的准确率。这在 5 年前是不可想象的——当时需要从零训练 LSTM，耗时数小时且准确率仅约 87%。
2. 第二，Loss 曲线的「训练-验证背离」是判断过拟合的核心信号，比 Accuracy 更敏感。本实验中验证 Loss 从第 2 个 Epoch 就开始预警，而验证 Accuracy 直到实验结束仍在上升——如果只看 Accuracy，很可能会误判并继续训练，导致更严重的过拟合。
3. 第三，单一的 Accuracy 指标远远不够。92.12% 看起来出色，但混淆矩阵和错误分析揭示：仍有 1,971 条评论被误判，且错误高度集中在转折、否定、混合情感、讽刺等特定语言模式上。理解模型在哪里犯错比知道错了多少更有价值。
4. 第四，情感分析的核心挑战不在于识别正面词汇，而在于理解否定、转折、讽刺等需要深层语义推理的语言现象。这些现象恰恰是 BoW 等传统方法完全无法处理的，也是 BERT 等预训练模型仍需改进的方向。

二 AI 工具使用说明

本次实验中使用了 Claude (Anthropic) 进行以下辅助：

1. 代码讲解：train.py / evaluate.py / inference.py 中每行代码的作用和底层原理
2. 环境配置：CUDA 版本选择、虚拟环境使用、pip 安装命令指导
3. 故障排查：缩进修复、代理网络问题诊断、Git 大文件推送失败处理
4. 报告撰写：实验报告的文字组织、格式排版和表达润色

所有代码的核心逻辑已经过本人理解和验证，可以独立解释每一部分的实现原理。报告中的错误案例分析由本人阅读误分类样本后归纳总结，AI 仅用于辅助文字组织。

三 参考文献

1. [1] Pang B, Lee L, Vaithyanathan S. Thumbs up? Sentiment Classification using Machine Learning Techniques. EMNLP, 2002.
2. [2] Wang S, Manning C D. Baselines and Bigrams: Simple, Good Sentiment and Topic Classification. ACL, 2012.
3. [3] Mikolov T, et al. Efficient Estimation of Word Representations in Vector Space. ICLR, 2013.
4. [4] Kim Y. Convolutional Neural Networks for Sentence Classification. EMNLP, 2014.
5. [5] Hochreiter S, Schmidhuber J. Long Short-Term Memory. Neural Computation, 1997.
6. [6] Vaswani A, et al. Attention Is All You Need. NeurIPS, 2017.
7. [7] Devlin J, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL, 2019.
8. [8] Radford A, et al. Improving Language Understanding by Generative Pre-Training. OpenAI, 2018.
9. [9] Hu E J, et al. LoRA: Low-Rank Adaptation of Large Language Models. ICLR, 2022.
10. [10] Pennington J, et al. GloVe: Global Vectors for Word Representation. EMNLP, 2014.
11. [11] Bojanowski P, et al. Enriching Word Vectors with Subword Information. TACL, 2017.
12. [12] HuggingFace. Transformers Library Documentation. <https://huggingface.co/docs>.